Data Science Projects

▼ NYC Taxi Project

Dataset: NYC Taxi dataset

▼ 1. Research Problem

Bối cảnh

NYC là một trong những thành phố có hệ thống taxi lớn nhất thế giới. Hệ thống taxi tạo ra hàng trăm triệu chuyến đi mỗi năm, tạo ra một nguồn dữ liệu rất lớn để nghiên cứu urban mobility.

Vấn đề chính:

- taxi demand thay đổi theo time, location, weather
- traffic pattern phức tạp
- resource allocation khó tối ưu

Problem statement

Phân tích và dự đoán nhu cầu taxi theo không gian và thời gian để hiểu các yếu tố ảnh hưởng đến hành vi di chuyển trong đô thị

▼ 2. Research Questions

RQ1 - Mobility pattern

Taxi demand thay đổi như thế nào theo:

- time-of-day
- day-of-week
- location

RQ2 - Spatial demand

Những khu vực nào trong NYC có:

- pickup demand cao nhất
- dropoff density cao nhất

RQ3 - Temporal forecasting

Có thể dự đoán taxi demand trong tương lai hay không?

RQ4 - Causal factors

Các yếu tố nào ảnh hưởng đến demand:

- weather
- rush hour
- airport trips
- holidays

RQ5 - Travel efficiency

Các yếu tố ảnh hưởng đến:

- trip duration
- trip speed

▼ 3. Dataset

▼ NYC Taxi Dataset

- VendorID (integer): Cho biết nhà cung cấp hệ thống menter / telemetry của taxi.
  - 1- Creative Mobile Technologies
  - 2- Curb Mobility
  - 6- Myle Technologies
  - 7- Helix

  ⇒ Có thể dùng để kiểm tra bias giữa các vendor, kiểm tra khác biệt trong distance measurement

- lpep_pickup_datetime (datetime): Thời điểm taximeter được bật (bắt đầu chuyến đi).
    - Feature engineering: hour, day_of_week, month, is_weekend, rush_hour
- lpep_dropoff_datetime (datetime): Thời điểm taximeter tắt (kết thúc chuyến đi).
    - Feature: trip_duration = dropout - pickup
- store_and_fwd_flag: Cho biết dữ liệu chuyến đi có được lưu tạm rồi gửi sau không.
    - Y: store and forward
    - N: real time

  ⇒ Khi taxi mất kết nối internet → dữ liệu được lưu trong xe
- RatecodeID: Loại giá cước được áp dụng cho chuyến đi
    - 1- Standard rate
    - 2- JFK
    - 3- Newark
    - 4- Nassau / Westchester
    - 5- Negotiated
    - 6- Group ride
    - 99- Unknown
- PULocationID: Taxi zone nơi đón khách
    - Dùng để demand analysis, hotspot detection, spatial clustering
- DOLocationID: Taxi zone nơi trả khách
- passenger_count: Số hành khách trong xe
- trip_distance: Khoảng cách chuyến đi (mile)
    - Feature engineering: trip_speed = distance / duration
- fare_amount (float): Giá cước chính của chuyến đi

- extra: Các phụ phí bổ sung
- mta_tex: Thuế MTA
- tip_amount: tiền tip
- tolls_amount: phí cầu đường
- improvement_surcharge: Phí cải thiện hệ thống taxi
- total_amount: Tiền khách phải trả
- payment_type: phương thức thanh toán
  - 0- Flex Fare
  - 1- Credit card
  - 2- Cash
  - 3- No charge
  - 4- Dispute
  - 5- Unknown
  - 6- Voided trip
- trip_type: Cách taxi được gọi
  - 1- Street hail
  - 2- Dispatch
- congestion_surcharge: Phí tắc nghẽn giao thông tại NYC.

▼ Analyze

Nguồn: NYC TLC Trip Record Data

Dataset chứa:

- hàng trăm triệu trips
- dữ liệu trong nhiều năm

Variables

- Temporal: pickup_datetime
- dropoff_datetime

Spatial

- pickup_location_id
- dropoff_location_id

Trip characteristics

- trip_distance
- fare_amount
- tip_amount
- passenger_count

Derived features

Cần tạo thêm

- trip_duration
- trip_speed
- hour_of_day
- day_of_week
- is_weekend

▼ 4. Methodology

Phase 1 - Data Engineering

- Data cleaning
  - remove invalid trips
  - remove negative fares
  - remove extreme outliers
- Feature engineering
  - trip_duration
  - trip_speed
  - pickup_hour

    - pickup_day
    - is_weeked
- Spatial mapping

  Map location ID → geographic zone

    - Tools: geopandas, shapely

Phase 2 - Exploratory Data Analysis (EDA)

- Temporal analysis
    - Phân tích demand theo: hour, day, month
    - Visualizations:
        - trip count by hour
        - trip count by day
- Spatial analysis
    - Phân tích: pickup hotspots, dropoff hotspots
    - Visualization: heatmap of taxi demand
    - Tools: geopandas, kepler.gl
- Trip efficiency
    - trip duration distribution
    - trip speed distribution

Phase 3 - Spatial Demand Analysis

- Mục tiêu: Xác định taxi hotspots
- Methods:
    - Spatial clustering: DBSCAN, HDBSCAN
    - Kernel density estimation:
        - Phân tích: high demand regions
        - Outcome: NYC taxi demand map

Phase 4 - Demand Forecasting

- Mục tiêu: dự đoán taxi demand
- Target: number of trips per zone per hour
- Model:
  - Statistical models: ARIMA, SARIMA
  - ML models: Random forest, XGBoost, LightGBM
  - Deep learning model: LSTM, Temporal Fusion Transformer
  - Evalution: RMSE, MAE, MAPE

Phase 5 - Causal Analysis

- Mục tiêu: Hiểu các yếu tố ảnh hưởng đến taxi demand
- Treatment variable: rain, rush hour, holiday
- Methods: Propensity Score Matching, Difference-in-Difference
- Example result: Rain increases taxi demand by 15%

▼ 5. Experiments

Experiment 1

Temporal demand pattern

Goal: analyze daily mobility pattern

Experiment 2

Spatial hotspots detection

Goal: identify high-demand regions

Experiment 3

Trip duration prediction

Goal: predict trip duration

Models: linear regression, random forest, xgboost

Experiment 4

Demand forecasting

Goal: predict taxi demand

Experiment 5

Causal impact of weather

Goal: estimate weather effect

▼ 6. Expected Outcomes

Insight outcomes

- Taxi demand peaks at 6-8PM
- Airport trips have higher tips
- Rain increases taxi demand

Modeling outcomes

- trip duration prediction model
- demand forecasting model

Spatial outcomes

- NYC taxi demand map
- hotspots analysis

▼ Project structure

nyc-taxi-data-science/

data/
raw/
processed/

notebooks/
01_eda.ipynb
02_spatial_analysis.ipynb
03_modeling.ipynb

```
src/
data_processing.py
feature_engineering.py
models.py

experiments/

reports/
figures/
paper_draft.md
```